任务一　基于神经渲染的街景三维重建技术

子任务二

[redacted]

(申请优秀营员)

2024年7月18日

目录

1 子任务二：基于 MARS 的街景三维重建 **2**

1.1 MARS方法概述 2

1.2 针对背景节点的建模 3

1.2.1 场景表示 3

1.2.2 样本采集和属性推理 3

1.2.3 射线查询与距离参数化 3

1.2.4 采样策略 Proposal Sampler 4

1.2.5 天空模型 4

1.2.6 背景正则化 5

1.3 针对前景节点的建模 5

1.3.1 改进的类别级表征 5

1.3.2 采样策略 coarse-to-fine 6

1.3.3 实例编辑 6

1.4 组合渲染 6

1.5 优化 6

1.6 当前存在的问题与挑战 7

1 子任务二：基于 MARS 的街景三维重建

本节将要介绍《MARS: An Instance-aware, Modular and Realistic Simulator for Autonomous Driving》中的关键技术和基本原理，接下来以本文指代该论文。本文方法的创新点主要分为三个部分：实例感知、模块化设计和现实性提升[**1**]。

实例感知

在实例感知方面，本文提出了一种**分别对前景和背景进行建模**的方法。通过使用独立的神经网络，模拟器可以分别控制前景实例的静态（例如尺寸和外观）和动态（例如轨迹）属性。这种方法允许更精细地调整每个实例的特性，从而提高模拟的灵活性和真实性。

具体来说，前景节点负责动态对象的建模，输入包括RGB图像、传感器姿态和物体轨迹等。通过将射线原点和方向从世界坐标系转换到实例坐标系，前景节点能够准确处理动态对象的运动。样本采集和属性推理使用改进的类别级神经网络，确保了动态对象的细节和真实感。背景节点则负责静态部分的建模，采用无界NeRF方法对大规模场景进行处理，通过正则化策略解决了背景样本可能落在前景边界框内的问题，避免了渲染过程中的伪影现象。

模块化设计

在模块化设计方面，本文的模拟器提供了灵活的模块选择，包括不同的NeRF相关骨干网络、采样策略和输入模式等。背景节点和前景节点分别采用不同的NeRF框架，满足静态和动态对象的不同需求。这种设计不仅提高了渲染的真实性和灵活性，还支持最新的重建方法，并且可以方便地进行各种实验配置。具体来说，背景节点使用基于网格的NeRF和proposal sampler，实现高效的静态背景渲染；前景节点使用改进的类别级表征和由粗到精的采样策略，确保动态前景对象的细节和真实感。

现实性提升

在提升现实性方面，本文通过优化模块选择，达到了照片现实主义的最新标准。具体而言，作者通过实验验证了不同模块组合对模拟效果的影响，并选择了最佳组合以实现最高的照片现实性表现。背景节点和前景节点的模块化设计使得MARS能够分别采用不同的NeRF框架，满足静态和动态对象的不同需求。实验结果表明，相较于其他SOTA方法，MARS在KITTI和V-KITTI数据集上有了很大提升，特别是在动态场景中避免了伪影的产生，并实现了**以实例感知的方式编辑场景**。

1.1 MARS方法概述

如图1所示，本文的框架旨在通过构建组合神经辐射场（NeRFs）来提供逼真的传感器模拟。该框架将场景分解为背景节点和多个前景节点，从而能够分别建模静态和动态元素。系统输入包括RGB图像、传感器姿态、目标轨迹、深度图和语义分割掩码。首先，选择不同的架构（背景节点使用基于网格的NeRF，前景节点使用改进的类别级表征），然后利用多种采样器（背景节点使用proposal sampler，前景节点使用coarse to fine）对场景和对象节点进行采样，并计算射线进入和离开对象的距离。接着，通过在大规模背景节点中对3D点进行采样，利用神经表示网络获取点的属性，并将射线原点和方向从世界坐标转换为实例帧，查询前景对象节点的属性。最终，从背景和前景节点获取的样本会被合并并排序，通过渲染器进行体渲染，生成包括RGB图像、深度图和语义分割图在内的像素级渲染结果。对于前景节点，本文支持基于代码表示的表征$f(\mathbf{x},\mathbf{d},\mathbf{z})=(\mathbf{c},\sigma)$（其中$\mathbf{z}$为实例的潜在代码）和传统表征，从而实现对对象轨迹和外观的实例编辑。这样，整个框架实现了逼真的传感器感知信号生成和对象轨迹与外观的实例编辑。

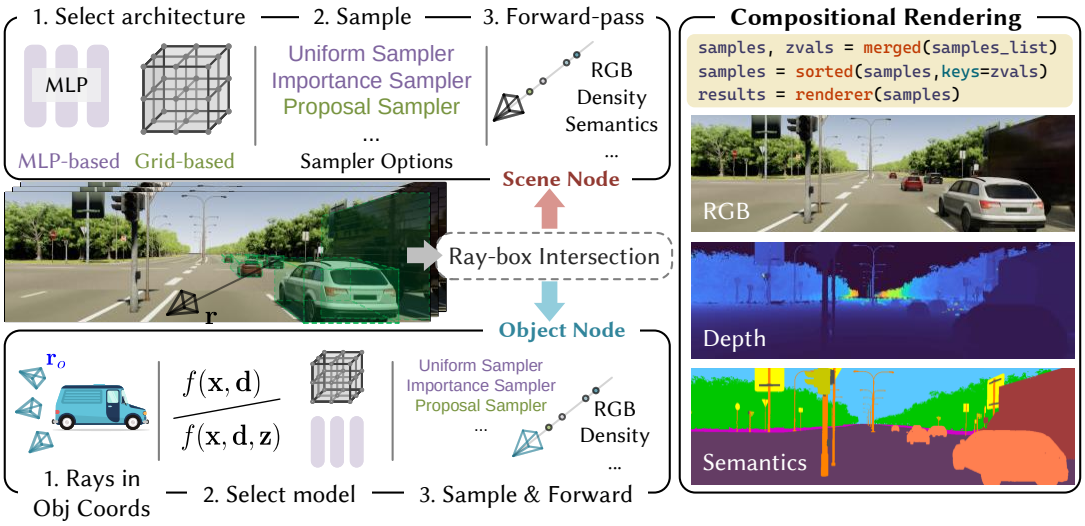


图 1: MARS流程图[1]

1.2 针对背景节点的建模

背景节点利用基于网格的NeRF和proposal sampler来实现高效的静态背景渲染。基于网格的NeRF利用哈希网格体素在空间中存储变体特征，通过三线性插值和浅MLP解码来实现场景的细致表达。

1.2.1 场景表示

场景表示使用大规模无限NeRF作为背景节点，并使用对象中心的NeRF作为前景实例。该框架支持多种NeRF架构，包括基于MLP的方法和基于网格的方法，具有设计上的灵活性。

1.2.2 样本采集和属性推理

背景节点在射线上采样一组3D点，并使用神经网络推理这些点的属性，包括RGB颜色、密度和语义信息。它的采样和推理过程类似于传统的NeRF方法，但其设计为无界NeRF，以处理大规模场景。

1.2.3 射线查询与距离参数化

给定射线 r，首先计算每个可视物体的3D边界框的交集，获取射线进入和离开的距离。为了有效处理大规模场景，模型采用收缩函数来重新参数化高斯分布：

$$\text{contract}(\mathbf{x}) = \begin{cases} \mathbf{x} & \text{if } \|\mathbf{x}\| \le 1, \\ \left(2 - \frac{1}{\|\mathbf{x}\|}\right)\left(\frac{\mathbf{x}}{\|\mathbf{x}\|}\right) & \text{if } \|\mathbf{x}\| > 1. \end{cases} \tag{1}$$

这种设计与 NDC 具有相同的动机：远处的点应该按比例分布到视差（逆距离）而不是距离。

在 NeRF中，用于渲染图像的关键步骤之一是从相机到场景中各点的射线采样。传统上，这些射线的距离 t 通常是从近平面 t_n 到远平面 t_f 均匀采样的。这种采样方法在处理有界场景时效果显著，但在处理无界场景时，特别是需要同时考虑远处和近处的情况下，存在一些限制。

为了解决这个问题，NeRF 引入了归一化设备坐标（NDC）参数化方法，其中射线的采样距离实际上是在视差（逆深度）空间中均匀分布的，而不是在欧几里得距离空间中。视差是深度的倒数，因此较远的点具有较小的视差，较近的点具有较大的视差。这种设计适用于无界场景，因为它可以有效地处理从相机到远处景物的距离范围。

具体来说，这里定义了一个从欧几里得距离 t 到归一化射线距离 s 的映射：

$$s \triangleq \frac{g(t) - g(t_n)}{g(t_f) - g(t_n)}, \quad t \triangleq g^{-1}\left(s \cdot g(t_f) + (1-s) \cdot g(t_n)\right) \tag{2}$$

其中 $g(x) = 1/x$，这个选择确保了射线样本在视差空间内均匀分布。换句话说，通过这种映射可以在归一化射线距离 $s \in [0, 1]$ 上均匀采样，然后通过逆映射 $t = g^{-1}(s \cdot g(t_f) + (1 - s) \cdot g(t_n))$ 得到对应的欧几里得距离 t。这种方法使得射线距离的采样在整个场景中保持一致，无论是远处还是近处的物体，都能够得到均匀的空间分布。

1.2.4 采样策略 Proposal Sampler

在本文中，重点使用了 proposal MLP 来提升渲染质量。proposal MLP 预测体积密度，并将其转换为proposal权重向量 $\hat{\mathbf{w}}$，这些权重用于采样提供给 NeRF MLP 的 s 间隔，后者预测自己的权重向量 $\mathbf{w}$ 以及用于渲染图像的颜色。

Mip-NeRF中的多尺度MLP通过反复查询和重新采样以提供更多样本，而proposal MLP则仅在一次评估中使用较少的样本，从而提高了模型的效率。proposal MLP主要负责生成一组proposal权重 $\hat{\mathbf{w}}$，这些权重是为了约束NeRF MLP生成的权重 $\mathbf{w}$。它的设计目的主要是为了在训练中引导NeRF MLP的学习方向。通过生成与NeRF MLP输出相一致的权重，有效地辅助NeRF MLP更好地学习到适合渲染真实色彩的权重参数。这种在线蒸馏的方法将NeRF MLP的知识转移到proposal MLP上，使模型在增加容量的同时，训练成本仅略微增加。

本文使用基于 Proposal 网络的分层采样策略。即使用一个轻量级网络，从空间点坐标估计体密度 $\hat{\sigma}$：

$$f_{Proposal}: \quad \mathbf{x} \rightarrow \hat{\sigma}(\mathbf{x}) \tag{3}$$

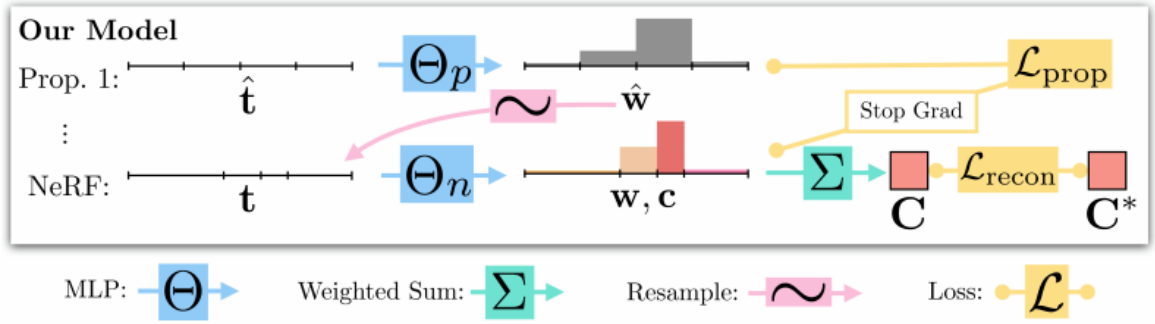


图 2: Mip-NeRF 360模型结构图[2]

结构图说明

1. **proposal MLP** (Θ_p) 预测体积密度并生成proposal权重向量 $\hat{\mathbf{w}}$。
2. 这些proposal权重用于采样 s 间隔，这些间隔提供给 **NeRF MLP** (Θ_n)。
3. NeRF MLP 预测最终的权重 $\mathbf{w}$ 和颜色 c。
4. 生成的权重和颜色用于重建图像 C，并通过图像重建损失 ($\mathcal{L}_{\text{recon}}$) 进行监督。
5. proposal MLP 通过与 NeRF MLP 的输出权重进行比较，生成proposal损失 ($\mathcal{L}_{\text{prop}}$)，并逐渐调整以捕捉 NeRF MLP 的知识。

1.2.5 天空模型

为了准确地模拟远处的天空，本文使用了基于MLP的球形环境图来处理在无限远处的外观：

$$f_{\text{sky}}(\mathbf{d}) = \mathbf{c}_{\text{sky}} : \mathbb{S}^2 \rightarrow \mathbb{R}^3 \tag{4}$$

为了避免天空颜色 $\mathbf{c}_{\text{sky}}$ 与背景和前景混合渲染导致的潜在不一致性，引入了二分类交叉熵（BCE）语义正则化：

$$\mathcal{L}_{\text{sky}} = \text{BCE}(1 - \texttt{accum}, \mathcal{S}_{\text{sky}}). \tag{5}$$

1.2.6 背景正则化

为了避免背景样本落在前景边界框内的问题，本文采用正则化策略最小化背景截断样本的密度和以解决背景和前景样本之间的冲突:

$$\mathcal{L}_{\texttt{accum}} = \sum_{P_i^{(\text{tr})}} \sigma_i, \tag{6}$$

其中 $\{P_i^{(\text{tr})}\}$ 表示截断背景样本。

1.3 针对前景节点的建模

前景节点在MARS系统中负责动态对象建模，通过RGB图像、传感器姿态、物体轨迹等输入数据，进行射线查询。根据对象轨迹将射线原点和方向从世界坐标系转换到实例坐标系。采用改进的类别级神经网络推理属性（如RGB颜色、密度、语义信息），最终与背景节点的样本合成，生成高质量渲染图像。

1.3.1 改进的类别级表征

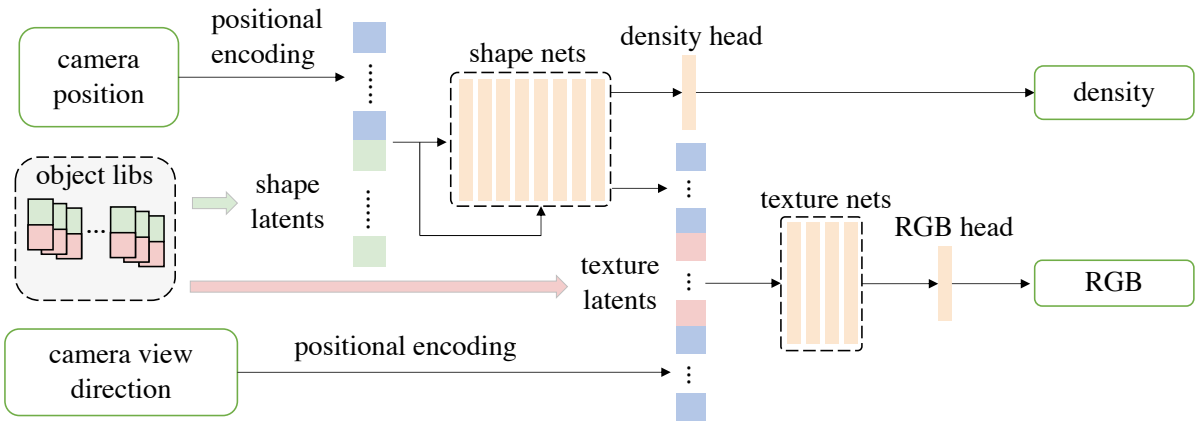


图 3: 类别级别模型中的形状与纹理解耦[**1**, **3**]

如图 3 所示，在前景节点的改进方法中，形状和纹理被解耦为两个部分的潜在编码，并存储在对象库中。在渲染过程中，查询这些潜在编码并将其融入NeRF模型，通过形状和纹理网络分别对实例的形状和纹理进行建模，具体步骤如下所示：

1. **解耦形状和纹理**：我们将每个对象实例的形状和纹理解耦成两个部分的潜在编码，并在测试序列上优化这些潜在编码，将它们存储在对象库中。对象库包含所有实例的形状和纹理潜在编码。
2. **查询对象库**：在渲染过程中，我们从对象库中查询先验信息并将它们融入NeRF模型中。这些先验信息包括形状潜在编码和纹理潜在编码。
3. **形状和纹理网络**：
   - **形状网络（Shape Net）**：形状网络是一个8层的MLP，用于建模对象实例的形状。它接收位置编码的相机位置和形状潜在编码作为输入，并输出表示对象形状的特征。
   - **纹理网络（Texture Net）**：纹理网络是一个4层的MLP，遵循vanilla NeRF设计，用于建模对象实例的纹理。它接收位置编码的视角方向和纹理潜在编码作为输入，并输出对象的纹理信息。

4. **特征组合：**
   - 将位置编码的相机位置和形状潜在编码连接起来，并输入到形状网络以建模实例的形状。
   - 将形状网络的输出特征与位置编码的视角方向**d**和纹理潜在编码堆叠，并将生成的输入传递给纹理网络以获取实例的纹理。

1.3.2 采样策略 coarse-to-fine

前景节点的采样方法对应经典NeRF论文中的粗到细方法（coarse-to-fine），主要步骤包括：

1. 粗采样：在光线上均匀采样，根据体渲染公式获得每个采样点的权重（由体密度和位置远近共同决定）。
2. 细采样：根据粗采样获得的权重，做一个光线上的归一化，将权重之和置为1，得到概率密度函数（PDF）。根据PDF来精采样，即让更重要的线段上有更多的采样点。
3. 递归优化：通过迭代优化，使得细采样逐渐逼近真实的场景辐射场分布，从而提高渲染精度。

1.3.3 实例编辑

由于前景对象是单独建模的，MARS允许对前景对象进行实例感知的编辑。这包括删除实例、添加新实例、编辑对象轨迹等操作。该部分通过修改代码中的./scripts/cicai_render.py实现：从batch中读取物体的姿势和旋转信息，然后修改姿势和旋转张量。

1.4 组合渲染

该框架通过组合来自背景和前景节点的样本来执行组合渲染。该过程包括计算光线交点、转换样本以及体渲染，以生成逼真的图像、深度图和语义分割结果。

为了在给定的相机姿态 $\mathcal{T}_i$ 下渲染图像，首先在每个像素处投射一条光线 $\mathbf{r} = \mathbf{o} + t\mathbf{d}$。对于每条光线 $\mathbf{r}$，计算所有可见前景节点 O_{ij} 的交集区间 $[t_{\text{in}}, t_{\text{out}}]$ (见图 4)，并将沿光线的样本 $\{P_k^{\text{obj-j}}\}$ 从世界空间转换到每个前景的规范空间。同时，在光线上采样一组3D点作为背景样本 $\{P_k^{\text{bg}}\}$。所有节点的样本首先通过对应的网络得到逐点颜色 $\{\mathbf{c}_k^{\text{bg, obj}}\}$、密度 $\{\sigma_k^{\text{bg, obj}}\}$ 和前景语义逻辑值 $\{\mathbf{s}_k^{\text{bg}}\}$。

考虑到前景样本的语义属性实际上是它们的类别标签，为此创建一个one-hot向量：

$$\mathbf{s}_k^{\text{obj-j}}[l] = \begin{cases} \sigma_k^{\text{obj-j}} & \text{if } l = \text{category of j's instance} \\ 0 & \text{otherwise} \end{cases}, \text{for } l \text{ in category.} \tag{7}$$

为了聚合逐点的属性，本文按光线距离对所有样本进行排序，并使用标准的体渲染过程来渲染逐像素的属性：

$$\hat{\mathbf{c}}(\mathbf{r}) = \sum_{P_i} T_i \alpha_i \mathbf{c}_i + (1 - \texttt{accum}) \cdot \mathbf{c}_{\text{sky}}, \quad T_i = \exp(-\sum_{k=1}^{i-1} \sigma_k \delta_k), \tag{8}$$

$$\hat{d}(\mathbf{r}) = \sum_{P_i} T_i \alpha_i t_i + (1 - \texttt{accum}) \cdot \texttt{inf}, \ \hat{\mathbf{s}}(\mathbf{r}) = \sum_{P_i} T_i \alpha_i \mathbf{s}_i + (1 - \texttt{accum}) \cdot \mathbf{s}_{\text{sky}}, \tag{9}$$

其中 $P_i \in \texttt{sorted}(\{P_i^{\text{bg, obj}}\}), \alpha_i = 1 - \exp(-\sigma_i \delta_i), \delta_i = t_{i+1} - t_i, \texttt{accum} = \sum_{P_i} T_i \alpha_i, \mathbf{c}_{\text{sky}}$ 是天空模型渲染的颜色，$\texttt{inf}$ 是上界距离，$\mathbf{s}_{\text{sky}}$ 是 $\texttt{sky}$ 类别的 one-hot 语义逻辑值。

1.5 优化

系统优化如下目标函数：

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{color}} + \lambda_2 \mathcal{L}_{\text{depth}} + \lambda_3 \mathcal{L}_{\text{sem}} + \lambda_4 \mathcal{L}_{\text{sky}} + \lambda_5 \mathcal{L}_{\texttt{accum}} \tag{10}$$

其中λ_{1-5}是加权参数。

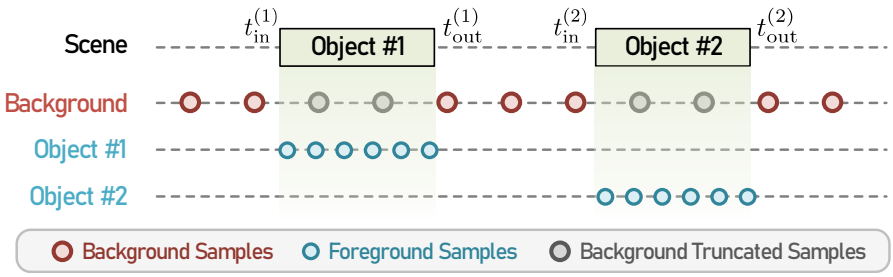


图 4: 无冲突采样过程的可视化展示（图中采用均匀采样方法，确保各节点内样本的采样区间没有重叠或冲突）[1]

颜色损失: 使用MSE最小化光度误差。

$$\mathcal{L}_{\text{color}} = ||\mathbf{c}(\mathbf{r}) - \hat{\mathbf{c}}(\mathbf{r})||_2^2 \tag{11}$$

深度损失: 使用深度数据或单目深度网络监督几何形状。

$$\mathcal{L}_{\text{depth}} = \begin{cases} \sum_k \log h_k \exp\left(-\frac{(t_k - \mathcal{D}(\mathbf{r}))^2}{2\hat{\sigma}_i^2}\right) \delta_k & \text{if depth data is available} \\ \sum_{\mathbf{r}} \left\| w\hat{\mathbf{d}}(\mathbf{r}) + q - \mathcal{D}(\mathbf{r}) \right\|_2^2 & \text{if depth data is not available} \end{cases} \tag{12}$$

其中 $\hat{\sigma}_i$ 是平均重投影误差，w 和 q 是可学习的缩放和位移因子，通过训练优化以实现尺度和位移不变性。h_k 表示每个像素的权重，t_k 表示每条光线的采样深度，$\mathcal{D}(\mathbf{r})$ 表示深度值，$\hat{\sigma}_i$ 表示平均重投影误差，δ_k 表示光线采样间隔，$\mathbf{r}$ 表示光线，$\hat{\mathbf{d}}(\mathbf{r})$ 表示单目深度估计值。

语义损失: 使用交叉熵进行语义监督。

$$\mathcal{L}_{\text{sem}} = \texttt{CrossEntropy}(\mathbf{s}(\mathbf{r}), \mathcal{S}(\mathbf{r})) \tag{13}$$

天空损失: 引入BCE正则化以确保天空模型一致性。

$$\mathcal{L}_{\text{sky}} = \texttt{BCE}(1 - \texttt{accum}, \mathcal{S}_{\text{sky}}) \tag{14}$$

累积损失: 最小化截断背景样本的影响。

$$\mathcal{L}_{\text{accum}} = \sum_{P_i^{(\text{tr})}} \sigma_i \tag{15}$$

1.6 当前存在的问题与挑战

本文方法旨在通过神经渲染技术进行街景重建。然而，该方法存在以下限制：

1. **训练时间长**：该方法需要数小时的训练时间，无法实现实时渲染。这意味着在实际应用中可能需要优化或改进以提高效率。
2. **动态镜面效应处理不足**：当前方法未能充分考虑玻璃或其他反光材料上的动态镜面效应。这种不足可能导致渲染图像中出现伪影，从而影响图像的真实性和细节表现。
3. **未来改进方向**：
   - **模拟效率**：提高方法的模拟效率是未来的一个重要工作方向。通过优化算法和硬件加速等手段，减少训练和渲染所需的时间。
   - **视角依赖效应**：改进对视角依赖效应的处理，以更真实地表现物体表面的反光和动态变化。这将提高渲染图像的真实感和视觉效果。

References

[1] Z. Wu et al., ”Mars: An instance-aware, modular and realistic simulator for autonomous driving,” Artificial Intelligence, pp. 3–15, 2024. doi: 10.1007/978-981-99-8850-1_1.

[2] J. T. Barron, B. Mildenhall, D. Verbin, P. P. Srinivasan, and P. Hedman, "Mip-NeRF 360: Unbounded Anti-Aliased Neural Radiance Fields," in *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 5460-5469, doi: 10.1109/CVPR52688.2022.00539.

[3] T. Liu, H. Zhao, Y. Yu, G. Zhou and M. Liu, "Car-Studio: Learning Car Radiance Fields From Single-View and Unlimited In-the-Wild Images," in IEEE Robotics and Automation Letters, vol. 9, no. 3, pp. 2024-2031, March 2024, doi: 10.1109/LRA.2024.3349949.

[4] https://github.com/theNded/mini-omnidata